基于语料库的短语研究新路径:“词性序列”研究

林 铃 刘 明
(上海交通大学,上海,200240;香港理工大学,香港,999077)

摘要:短语研究一直是语料库语言学的核心议题之一。本文系统回顾了现有的短语研究方法和模型,并重点介绍了短语研究的一种新路径,即“词性序列”研究。本文不仅介绍了该方法的定义和基本特征,还重点介绍了它在短语提取和分析、短语功能研究、语篇特征研究以及语言教学和学习上的意义。虽然该方法一直被国际和国内语言学界所忽视,但其为短语的提取和分析提供了新思路、新手段和新发现,为现有的短语研究提供了有益的补充,值得进一步深入研究和广泛推广。

关键词:短语;词性序列;多词序列;语料库语言学;N 元分析
[中图分类号]H08 [文献标识码]A [文章编号]1674-8921-(2025)04-0015-13
[doi 编码]10.3969/j.issn.1674-8921.2025.04.002

0. 引 言

短语研究一直是语料库语言学的研究重点之一(Stubbs 2007a; 卫乃兴 2009;李文中 2021; 甄凤超 2023)。语料库语言学研究发现,日常语言中充斥着大量的短语,如何提取和描述这些短语,是语料库语言学研究的核心议题之一,因此涌现了不同的分析方法和模型,如“拓展意义单位”(extended lexical units)(Sinclair 1998, 2004),“N 元分析”(n-grams)(Stubbs 2007b),“共现词列”(concgrams)(Cheng *et al*. 2006),等等。本文系统回顾了这些不同的分析模型和方法,并在此基础上着重介绍一种新的分析路径,即“词性序列”(PoS-gram)研究(Stubbs 2007a)。该方法虽然一直被国际和国内语言学界所忽视,但近年来逐渐受到国际语料库语言学界的关注(Thompson & Sealey 2007; Brett & Pinna 2015; Pinna & Brett 2018)。本文重点介绍该方法在短语研究上的优势及其可能的应用空间。

作者简介:林铃,上海交通大学外国语学院副教授、博士生导师。主要研究方向为语料库语言学、学术话语分析。电子邮箱:kathyll@sjtu.edu.cn;刘明,香港理工大学中文及双语系助理教授、博士生导师。主要研究方向为话语分析、语料库语言学。电子邮箱:mingl.liu@polyu.edu.hk
* 本文系国家社科基金项目“基于语类的英语局部语法研究”(编号 18CYY054)的阶段性成果。
引用信息:林铃、刘明. 2025. 基于语料库的短语研究新路径:“词性序列”研究[J].当代外语研究(4):15-27.

1. 基于语料库的短语研究

短语研究在传统的语言学研究中一直处于边缘地位，因为它们只关注语言中那些零碎的、特殊的“固定表达”(fixed expressions)，但语料库语言学将短语研究看作是语言研究的核心议题(Sinclair 1991，1996，2004；Stubbs 2009；卫乃兴 2009；甄凤超 2020)。语料库语言学主要关注语言中那些重复出现的语言结构，它不再局限于传统的“固定表达”，而是词汇语法的混合体(Stubbs 2007b)，短语因此泛指语言使用者用来表达意义的一切词汇共选现象(Cheng *et al*. 2009)。Sinclair 等(1970)指出，语言使用的一个基本原则就是“习语原则”(the idiom principle)。自然语言中充满了这种预制或半预制的短语结构，它们普遍存在于语言使用中，但人们却很少注意它们的存在(Sinclair 1991)。短语研究的基本假设是，语言的意义并非存在于孤立的词语中，而是存在于词汇和语法结合而成的型式 (pattern)与意义的共选之中，因此 Sinclair 等人将短语放在了语言研究的中心地位(Greaves & Warren 2010；卫乃兴 2012)，并提出了“扩展意义单位”(Sinclair 2004)。该模型指出，词汇意义的选择取决于五个范畴，包括语义偏向(semantic preference)、语义韵(semantic prosody)、搭配(collocation)、类联结(colligation)和内核(core)。语义韵和内核是意义选择的必要成分，而其他三类属于可选成分，但在实际操作中，该模型的分析通常存在较大的主观性，因此在大规模的语料库分析中存在一定的难度(Cheng 2006)。

而另一被广泛应用和推广的短语模型即是“N 元分析” (n-grams)，又称“机切词块”(lexical bundles)(Biber *et al*. 1999)，“复现词汇组合”(recurrent word combinations) (Altenberg 1998)，“词丛”(clusters)(Scott 1997)，等等。这里的 N 代表的是形符(token)的数量，它指一组连续出现的形符序列通过计算机对语篇中的词依次进行切分，从而分成特定数量的词语序列，并统计这些词语序列的使用频数，通常频数越高的词语序列，越能体现语篇的具体特征。N 的取值通常在 2 到 8 之间，但在实际分析中，通常会选择 4 词序列。这主要是因为 N 的取值范围如果小于 4，提取的词汇序列就会越多，这会大大增加分析的负担，但如果 N 的取值大于 4，则提取的词汇序列数量非常有限，不足以进行深入的分析(Hyland 2008)。虽然“N 元分析”非常准确高效，但它的缺陷也非常明显，即它只关注连续出现的词语序列，而无法提取具有位置和成分差异的短语结构，如 AB、BA、A * B、A ** B，等等。

在此基础上，一些学者又提出了非连续序列的 Skip-gram 模型，它和“N 元分析”一样，也有特定的长度，但允许存在一个或多个空缺位置，不仅可以提取 AB，还可以提取 A ** B、A *** B 等(Wilks 2005)。但 Skip-gram 模型虽然能够分析非连续的词语序列，却无法关注具有位置变化的词语序列，如 AB 和 BA。因此诞生了另一种分析模型，即 Concgram (Cheng 2006；Greaves & Warren 2010)。相比于 Skip-gram 和“N 元分析”，它能够同时兼顾短语内部结

构的成分和位置差异。Warren(2009)指出,Concgram 能够帮助区分三类多词单位:(1) 搭配框架(collocational frameworks)(Renouf & Sinclair 1991);(2)意义转换单位(meaning shift units)(Sinclair 1996, 1998);(3)组织框架(organizational frameworks)。但回顾上述分析模型和方法,不难看出它们都从词入手,关注词汇的共选模式,高度依赖频数这一标准,来判断短语结构的显著度,从而确定意义表达的基本单位(何安平 2013)。虽然近年来,也有一些学者提出型式语法(Hunston & Francis 2000)、短语框架等概念,但都没有脱离词汇这一基本出发点,短语的提取和分析也一直无法取得实质性的突破。

2. “词性序列”的定义及其特征

2.1 “词性序列”的定义

“词性序列”(PoS-gram)并不是一个全新的概念,但一直没有获得足够的重视和广泛的推广(Brett & Pinna 2015; Pinna & Brett 2018)。早在 2007 年,Stubbs 首次将其作为短语研究的三种方法之一进行介绍,并和另外两种分析方法进行比较,即“N 元分析”和“短语框架”(phrase-frame)(Stubbs 2007a)。其中“N 元分析”主要关注连续的词语序列,而短语框架比“N 元分析”更加灵活,它是一个具有某个特定成分空缺的短语结构,如 *play a * part in*,其中 *part* 之前的空缺位置可以由不同的形容词来体现,如 *large*、*significant*、*big*、*major*、*vital*、*essential*、*key*、*central*、*full*,等等。这些形容词通常属于有限的意义集合,能够让我们观察这些短语结构所能表达的意义潜势,短语框架通常依赖于“N 元分析”,即在提取特定词语序列时保留一个空缺位置。但“词性序列”指一组连续出现的词性类别标注序列,例如,PRP AT0 AJ0 NN1 代表了一个四词词性序列,即“介词”(Preposition) + “冠词”(Article) +“形容词(一般和积极的)”(Adjective [general or positive])+“普通名词单数”(Singular common noun),具体的体现形式包括: *on the other hand*、*for a long time*、*on the other side*、*at the other end*、*in the near future*、*in the middle east*、*in the long run* 等。它能够提取语料库中所有满足上述词性要求的四词序列。William Fletcher 将上述三种分析方法付诸实践,以 1 亿词的英语国家语料库(BNC)为数据,建立了“英语短语”(Phrases in English)数据库(网址: http://phrasesinenglish.org/),并同时提供上述三种检索方法。

2.2 “词性序列”的基本特征

“词性序列”分析必须基于提前进行词性标注的语料库,和“N 元分析”一样,它依赖于计算机软件对语篇中的“形符”进行依次分割,但它不是统计具体形符的发生频数,而是统计词性序列的发生频数,并在此基础上呈现每一个词性序列的所有体现形式,并统计同一词性序列的不同体现形式的“类符”(Type)和具体的“形符”(Token)数量。例如,在“英语短语”数据库中,使用频数最高的 6 词词性序列是 PRP AT0 NN1 PRF AT0 NN1, 其频数大于 3 的类符有 8485

个，而其形符有 62890 个。因此，相比于传统的 N 元分析，词性序列分析为短语的提取和分析提供了更加丰富的分析维度和视角。研究者既可以分析语料库中词性序列的使用频数高低，也可以分析它们具体体现形式的类符和形符的差异。如果在形符数量一致的情况下，类符频次越高，说明这一词性序列的体现形式更加多样，反之则体现形式更加单调，说明某些特定词语序列的发生频数过高，这也有助于识别语言表达中的“固定表达”。

其次，词性序列能够帮助我们识别一些体现结构一致，但具体体现形式多样的短语结构。如上文所述，“N 元分析”只提取体现形式完全一致的词语序列，并且以它们的具体使用频数作为判断标准，来确定语言中那些具有显著度的短语表达，这就必然会遗漏一些由于体现形式多样，但每一个具体体现形式的实际使用频数并不高的短语结构和表达（Pinna & Brett 2018）。而这些体现形式多样但结构一致的短语表达却在语言的实际使用和研究中具有同等甚或更加重要的意义，它们不仅能够体现语言表达的创造性，还能够反映语言使用的心理和认知机制。

此外，“N 元分析”的理想分析序列是 4 词序列，这是由于词语序列越长，其重复发生的频率就越低，因此数量大于 5 的词语序列数量非常有限（见表 1）。

表 1 “英语短语”数据库中 n-gram 的形符和 PoS-gram 的类符数量

类别	2 词	3 词	4 词	5 词	6 词	7 词	8 词
n-gram（形符）	376777	309419	103459	21902	3961	964	411
PoS-gram（类符）	1340	8801	11930	5356	1062	110	6

“词性序列”类符的具体频数并不遵从这一规律，它呈现先高后低的趋势（见表 1），这主要是由于词性序列越短，重复发生的概率就越大，因此其类符的数量就越低，但 4 词词性序列的类符数量最高，说明其比较多样。但长度大于 5 之后又出现递减趋势，这是由于每一个词性序列都有着大量的体现形式，因此其实际使用频数依然比较高（见表 2 和表 3），其理想的词性序列长度是 6 词序列（Brett & Pinna 2015；Pinna & Brett 2018），这也说明“词性序列”比“N 元分析”更能够揭示语言的内部结构，因而具有更强大的解释力。

表 2 “英语短语”数据库中使用频率最高的 10 个 6 词词性序列

排序	词性序列	频数	示例
1	PRP AT0 NN1 PRF AT0 NN1	20,932	*at the end of the day*
2	PRP AT0 AJ0 NN1 PRF AT0	5,784	*on the other side of the*
3	AT0 AJ0 NN1 PRF AT0 NN1	4,024	*the other side of the scale*

(续表)

排序	词性序列	频数	示例
4	AT0 NN1 PRF AT0 AJ0 NN1	3,768	*the end of the Cold War*
5	NN1 PRP AT0 NN1 PRF AT0	3,194	*light at the end of the*
6	AT0 NN1 PRP AT0 NN1 PRF	3,035	*an increase in the number of*
7	PRP AT0 NN1 PRF DPS NN1	2,991	*for the rest of his life*
8	AT0 NN1 PRF AT0 NN1 PRF	2,955	*a hell of a lot of*
9	PRP AT0 NN1 PRF AT0 AJ0	2,634	*at the end of a long*
10	VVN PRP AT0 NN1 PRF AT0	2,229	*brought to the attention of the*

表 3 “英语短语”数据库中使用频率最高的 6 词词块示例

排序	示例	频数	排序	示例	频数
1	*at the end of the day*	747	11	*by the end of the month*	108
2	*by the end of the year*	441	12	*before the end of the year*	104
3	*in the middle of the night*	273	13	*on the edge of the bed*	104
4	*at the end of the year*	230	14	*at the beginning of the year*	91
5	*by the end of the century*	220	15	*by the department of the environment*	90
6	*at the turn of the century*	207	16	*on the floor of the house*	84
7	*at the end of the month*	178	17	*in the middle of the road*	83
8	*by the end of the decade*	130	18	*for the rest of the day*	82
9	*at the end of the season*	113	19	*at the back of the house*	80
10	*at the end of the war*	111	20	*in the middle of the room*	80

“词性序列”的构成单位是词性类别标注,其具体表征的是具有相同或相似语法结构的连续型多词序列,因而比“N 元分析”更具凝练概括性,更有利于识别语篇中隐藏着的、反复出现的重要语言型式结构,从语法和句法层面上提供了可能的分析视角,是对传统语料库语言学短语研究的有益补充。也正因其特殊的组成单位是词性类别,不同于传统的从词形出发的多词短语序列研究,“词性序列”在其每一词性类别位置上的词汇纵向选择上更具灵活性和变异度,可汇集词形语义完全相同、相近、部分相关,甚至语义上相反或无关(仅仅是词性相同)却出现在同一词性序列结构的词汇(Pinna & Brett 2018)。因此,**“词性序列”本质上不属于语料库语言学中的短语序列范畴,但却是有效提取和识别多种短语序列和语篇中高频复现的典型语言型式结构的重要途径 (Lin & Liu 2021)。**

语料库短语学中与“词性”或“词性序列”相关的一个重要概念是“类联接”(colligation)(Sinclair 1996)。在短语搭配研究中,“类联接”通常围绕“节点

词”(node)展开,关注“节点词与抽象的语法类别之间的共现”(Sinclair 1996:124)。然而,词性序列是基于语料库词性类别标注的基础上,以数据驱动方式自动化提取的、高频复现的词性类别标注线性共现序列(Stubbs 2007a),其各组成成分即词性类别之间的关系是平等的。因此,词性序列与“类联接”在内涵上有本质区别。

纵观国内外语料库短语学研究现状,发现现有研究长期聚焦于多词短语序列(multi-word sequences),而数据驱动、高频复现的词性标注序列的研究却寥寥无几。原因可能是在短语学理论构建层面,新弗斯语料库语言学强调词项的核心地位(与传统语法的“开放原则”相对立),在语言使用呈现的“短语”倾向中似乎更重视词与词的搭配共现(collocation/word co-occurrences)及其对意义实现的作用,而非语法词性范畴的共现 (Lin & Liu 2021)。相较于语言学界相关研究的相对匮乏,词性序列目前主要应用于自然语言理解和信息处理、文本挖掘及机器学习领域研究专注于开发、优化不同语言的语料库词性标注系统及提高计算机词性标注的加工质量 (卢伟胜等 2014)。

在语言学界,有关词性研究集中于考察特定文本中单一词类或不同词性分布的使用情况(王立非、文道荣 2017),或多个不同词类在使用及功能上的对比(吴君等 2021),或专门用途文本中词性类别转变的情况(刘永芳、陈宗利 2019)。而为数不多的词性序列研究目前主要应用于考察中介语语言发展(Lim *et al*. 2024)或专门文本特征研究(Lin & Liu 2021; Stefanowitsch, Middeke & Lin 2023)。例如,Lim 等(2024)基于四词词性序列分析和型式语法,发现两个不同水平的学习者在二语写作中语言使用的差异。Breeze (2019)系统对比四种商务法律文本词性序列的语言特征,发现文本类型和体裁交际目的直接影响语言型式使用的倾向性。Thompson 和 Sealey(2007)对比英国国家语料库的新闻、儿童小说、成人小说三个子语料库的词性序列特征,发现三个子语料库频率最高的词性标注序列均是“preposition-article-singular noun-*of*-article-singular noun”。Brett 和 Pinna(2015)以及 Pinna 和 Brett (2018)分析了旅游新闻语篇的词性序列,将之与 1 亿词次的英国国家语料库提取的词性序列进行统计性检验对比,发现旅游新闻话语的一个典型特征是多数高频词性序列都含有形容词最高级,这与旅游新闻语篇对外积极宣传、营销的交际意图密切相关。Lin 和 Liu (2021)将词性标注序列引入学术引言子体裁跨学科对比研究中,发现基于语料库的词性序列分析不仅能有效提取与专门学术用途文本典型交际功能相契合的高频词汇语法型式,且有助于我们甄别不同学科学术文本的语言风格。Stefanowitsch 等(2023)聚焦于学术英语口语,即四大著名网课平台 Coursera、edX、Udacity 和 Futurelearn 的慕课讲稿的两词关键词性序列,发现两词关键词性序列“名词-名词”和“形容词-名词”在使用上具有明显的学科差异:即前者在自然科学和生命科学领域中使用更多,这与硬学科文本中包含大量复杂的名词化专业术语有关;而后者在人文社科领域中使用更多,主要用作

名词短语的后置修饰。

简而言之,与多词短语序列相比,词性序列尚未引起语言学界足够的重视,但其具有独特的优势,即能有效辅助研究者提取语篇高频复现的典型语言型式结构,因而在语篇分析、语言功能研究和语言学习和教学中都具有巨大的学术价值和应用价值。

3. “词性序列”研究的意义

3.1 短语提取和分析

Stubbs(2009)指出,短语研究的目的是找出语言中重复出现的短语结构,并解释它们经常出现的原因,但如何提取和确定这些短语却显得非常困难(Butler 2003)。“词性序列”为短语的提取和分析提供了新思路、新手段和新发现。不同的观察方法会带来不同的发现,显微镜能够观察到微小的事物,望远镜能够观察远处的事物,而 X 光则能够窥探事物的内部(Stubbs 2007a)。由于短语本身的复杂性和多样性,到目前为止还不存在一个能够准确识别和提取语言中短语型式的分析方法和工具,而“词性序列”则为现有的分析方法和模型提供了一个新思路,为它们提供了有益的补充。

例如,Pinna 和 Brett (2018)分析了“英语短语”数据库中六词词性序列 PRP AT0 NN1 PRF DPS NN1,在数据库中共有 417 个类符,2987 个形符。他们先对这些形符按照第 6 个词排列,再按照第一个词排列,发现一组具有很多相同特征的短语,它们只在一两个位置上存在差异,见图 1。

(a) *with the* { *back* / *flat* / *palm* / *heel* } *of* { *his* / *her* / *your* / *my* } *hand*

(b) *out of the* [*corner of* { *her* / *his* } *eye* / { *corner* / *side* } *of* { *her* / *his* } *mouth*]

(c) *with the* { *shake* / *nod* / *toss* / *jerk* } *of* { *his* / *her* } *hand*

图 1　PRP AT0 NN1 PRF DPS NN1 的典型体现形式(Pinna & Brett 2018: 110)

在这些特定位置上的不同词汇自上而下按照频数高低顺序排列,其中 *with the back of his hand* 的频数最高,有 54 次,而其总数也就 111 次。*Out of the corner of her eye* 占总数 142 次中的 47 次。*With a shake of his hand* 占总数

28 个的 7 个。如图 1 所示，他们展示了三种典型的搭配型式。每一种型式内都存在着一两个位置的变化形式，但这些在特定位置上的词都属于特定的语义域。在图 1(a)中，在第一个变化位置出现的词都用来表示手的某些部位。在图 1(b)中，第一个变化位置和第二个变化位置表达同样的关系。而在图 1(c)中，变化位置表达了手的不同动作。这体现了词性序列在短语的提取和确定上具有无可比拟的优势。它们既可以体现短语的频数，也可以体现内在成分之间的关系和功能，以及在特定位置上的体现形式的变化。遗憾的是，之前的语料库语言学很少运用词性序列来提取短语(Pinna & Brett 2018)。因此，“词性序列”能够为短语研究提供新的思路，有助于发现语言中一些长期被忽视的语言型式。

3.2 语言功能研究

词性序列不仅能够帮助我们提取使用频率较多的短语表达，还能够提取使用频率较高的短语结构，这些特定的短语结构在实际的语言中往往表达特定的语用和话语功能。Pinna 和 Brett (2018)指出，“词性序列”研究能够帮助我们发现特定话语中最常见的语用功能。Morley 和 Shift(2006)就尝试混合使用“词性序列”和“短语框架”来提取中世纪后期英语布道中的指令性言语行为。而同一词性序列可能包含不止一种型式，即重复出现的句法和语义组合，它们可能对应几种不同的语用功能，而词性序列能够将这些具有特定语用功能的相同语言型式集中地呈现出来。这些功能可能是评价的，也可能是指称的，一旦揭示出特定的型式和功能之间的对应关系，就能准确地判断短语的存在。

Pinna 和 Brett(2018)则发现，在旅游报道中频数最高的 6 词词性序列是 AT0 AJ0 NN1 PRP AT0 NN1，其频数最高的体现形式是 *a great place for a resort*、*a great place for a honeymoon*、*a great position for a tour*、*a unsurpassable site for a picnic* 和 *a good base for a tour*。它们的主要功能是从特定的活动出发来评价一个目的地。联系它们发生的语域，可以总结出它们主要的语用功能，即对特定地点做出积极评价的功能。而在讣告中，具有较高显著度的一个 6 词词性序列是 AJ0 NN1 PRP AT0 NN1 PRF，它的主要体现形式包括：*important role as the president of*、*leading role as the secretary of*、*crucial part in the retrieval of*、*large role in the work of*、*leading figure in the implementation of*、*driving force behind the creation of*，等等。这与讣告的功能有关，即评价一个人对社会的贡献。而在讣告中另一显著度较高的 6 词词性序列是 PNP VBZ VVN PRP DPS NN1，它的主要体现形式是 *she is survived by his son*、*she is survived by her brother*、*she is survived by her husband*、*he is survived by his wife*、*she is survived by my father*、*he is survived by his daughter*，等等。其主要功能是用来安慰逝者的亲属。

3.3 语篇特征研究

通过研究不同体裁中的短语使用，可以帮助我们更好地了解不同体裁和语域中的语言使用(Biber *et al*. 1999；Cortes 2004；Carter & McCarthy 2006；

Hyland 2008)。Pinna 和 Brett(2018)指出,未来的研究就是比较不同语域的语篇能否通过它们特色的词性序列来区分。将词性特征和语类研究结合起来,可以用来区分不同类型的语篇(Breeze 2019)。Thompson 和 Sealey(2007)则比较了儿童小说、成人小说、新闻中的词性序列使用。他们主要比较了 6 词词性序列,研究发现,三类语料中使用最多的词性序列是一致的,即“preposition-article-singular noun-of-article-singular-noun”(PREP ART NN1 of ART NN1),并且儿童和成人小说中频率最高的四个词性序列是一样的,但新闻语料库中使用频率最高的四个词性序列有一个没有出现在其他两类语料中。

Pinna 和 Brett(2018)比较了新闻报纸不同栏目在词性序列的使用上是否存在差异。这些不同栏目包括新闻报道、体育报道、社论、读者来信和影评等。其基本的假设是不同的交际功能会导致不同的语言使用型式(Biber & Conrad 2009),包括不同句法结构的使用频率,这可以体现在词性序列的使用上。他们比较了来自十个不同语域的语料,包括犯罪、银行、世界、政治、旅行、电影、教育和足球、科技和讣告。通过将这些子语料库分别与 BNC 语料库作比较,得到它们各自的关键词性序列(key PoS-grams)。他们进一步比较了犯罪、旅游和讣告类新闻的关键词性序列,发现在三个语料库中,最典型的句法结构都是以名词短语为主,但它们之间也存在一些差异,比如专有名词在犯罪报道和讣告中使用频率最高,而犯罪报道中动词的使用频率最高。这体现了旅游和讣告中重复出现的型式主要用来确认和描述事物,讣告更喜欢直接用名称来指称物体,而犯罪报道主要关注事物所经历的过程。此外,Brett 和 Pinna(2015)将 BBC 网站上的旅游新闻英语语篇和 BNC 语料库进行比较,从而得出该语料库中的关键词性序列,发现形容词最高级是旅游评论这一语体的重要特征。因此,“词性序列”分析能够在不同维度上呈现不同类型的语篇特征差异,具有较大的解释力。

3.4 语言学习和教学

Greaves 和 Warren(2010)指出,多词短语序列的研究对语言学习和教学、语言研究、专门用途英语研究和学术英语研究都具有重要的意义。尽管语料库短语学多词序列研究成果丰硕,但它们多以具体词形出发,获取的高频多词序列多数呈现碎片化、结构不完整的特征,难以发现潜藏的、反复出现的语言型式结构,因此教学价值常常为人诟病(雷蕾等 2017),而词性序列研究能够提取语篇高频复现的典型语言型式结构,多层次考察语篇词汇与语法的共选、词汇与词汇的共选、词汇和语法相结合而成的型式与意义,为语言学习和教学提供丰富的素材。

例如,Lin 和 Liu (2021)系统考察了计算机工程与认知语言学两个学科学术论文引言子体裁的关键词性序列及其表征的典型型式结构、语义和话语功能。研究发现,两学科学术语篇引言中都频繁使用表达研究目的的 6 词词性序列 IN DT JJ NN VBD TO(体现形式如 *of the present study was to*、*of the current investigation was to*)和 DT JJ NN VBD TO VV(体现形式如 *the*

present study was to examine、*the present experiment was to investigate*、*the current study was to test*),它们显示了大量形式多变但功能一致的短语型式,从而为学术英语写作的教学和学习提供了直观有效的素材。在实际教学过程中,我们既可以让语言学习者自己观察和提取他们所关注的特定词性序列及其体现形式,从而为语言教学和学习提供一种行之有效的手段,也可以将现有的研究成果进行总结和归纳,编纂相应的短语词典(许家金 2017),从而为语言的教学和学习提供丰富的教学资源。因此,如何更好地将词性序列研究和专门(学术)用途英语学习和教学结合起来是一个值得继续深入探讨的话题。

4. 结 语

卫乃兴(2009)指出,短语研究在未来相当长的时期内仍将是语料库语言学的核心议题之一,而短语研究的可持续发展离不开新思路和新方法的挖掘和开发。本文重点介绍了"词性序列"研究的基本特征及其可能的应用前景,希望能够引起国内语言学界的重视,为现有的短语研究注入新的活力。但正如 Pinna 和 Brett (2018)所说,该方法还处在早期的发展阶段,还有许多亟待完善和补充的地方,包括如何利用统计的方法,证明所确定型式的显著度等。这需要有志于短语研究的专家和学者一起努力,不断拓展短语研究的边界,为未来的短语研究和语料库语言学研究提供更加丰硕的成果。

参考文献

Altenberg, B. 1998. On the phraseology of spoken English: The evidence of recurrent word-combinations [A]. In A. P. Cowie (ed.). *Phraseology: Theory, Analysis and Applications* [C]. Oxford: Oxford University Press. 101-122.

Lin, L. & M. Liu. 2021. Towards a part-of-speech (PoS) gram approach to academic writing: A case study of research introductions in different disciplines [J]. *Lingua* (4): 1-18.

Biber, D. & S. Conrad. 2009. *Register, Genre and Style* [M]. Cambridge: Cambridge University Press.

Biber, D., S. Johansson, G. Leech, *et al*. 1999. *Longman Grammar of Spoke n and Written English* (Vol. 2) [M]. London: Longman.

Breeze, R. 2019. Part-of-speech patterns in legal genres [A]. In T. Fanego & P. Rodríguez-Puente (eds.). *Corpus-based Research on Variation in English Legal Discourse* (Vol. 91) [C]. Amsterdam: John Benjamins. 79-103.

Brett, D. & A. Pinna. 2015. Patterns, fixedness and variability: Using PoS-grams to find phraseologies in the language of travel journalism [J]. *Procedia-Social and Behavioral Sciences* (3): 52-57.

Butler, C. S. 2003. Multi-word sequences and their relevance for recent models of Functional Grammar [J]. *Functions of Language* (2): 179-208.

Carter, R. & M. McCarthy. 2006. *Cambridge Grammar of English* [M]. Cambridge: Cambridge University Press.

Cheng, W. 2006. Describing the extended meanings of lexical cohesion in a corpus of SARS spoken discourse [J]. *International Journal of Corpus Linguistics* (3): 325-344.

Cheng, W., C. Greaves & M. Warren. 2006. From n-gram to skipgram to concgram [J]. *International Journal of Corpus Linguistics* (4): 411-433.

Cheng, W., C. Greaves, J. Sinclair, *et al*. 2009. Uncovering the extent of the phraseological tendency: Towards a systematic analysis of concgrams [J]. *Applied Linguistics* (2): 236-252.

Cortes, V. 2004. Lexical bundles in published and student disciplinary writing: Examples from history and biology [J]. *English for Specific Purposes* (4): 397-423.

Greaves, C. & M. Warren. 2010. What can a corpus tell us about multi-word units? [A]. In O. K. Anne & M. Michael (eds.). *The Routledge Handbook of Corpus Linguistics* [C]. New York: Routledge. 240-254.

Hunston, S. & G. Francis. 2000. *Pattern Grammar: A Corpus-driven Approach to the Lexical Grammar of English* [M]. Amsterdam and Philadelphia: John Benjamins.

Hyland, K. 2008. As can be seen: Lexical bundles and disciplinary variation [J]. *English for Specific Purposes* (1): 4-21.

Lim, J. D., O. Mark, G. Pérez-Paredes, *et al*. 2024. Exploring part of speech (pos) tag sequences in a large-scale learner corpus of L2 English: A developmental perspective [J]. *Corpora* (1): 31-59.

Morley, B. & P. Shift. 2006. Towards the automatic identification of directive speech acts [A]. In R. Facchinetti & M. Rissanen (eds.). *Corpus-based Studies of Diachronic English* [C]. Bern: Peter Lang. 95-112.

Pinna, A. & D. Brett. 2018. Constance and variability: Using PoS-grams to find phraseologies in the language of newspapers [A]. In J. Kopaczyk & J. Tyrkkö (eds.). *Applications of Pattern-driven Methods in Corpus Linguistics* [C]. Amsterdam: John Benjamins. 107-130.

Renouf, A. & J. Sinclair. 1991. Collocational frameworks in English [A]. In K. Aijmer & B. Altenberg (eds.). *English Corpus Linguistics* [C]. Harlow: Longman. 128-143.

Scott, M. 1997. *Wordsmith Tools Manual* [M]. Oxford: Oxford University Press.

Sinclair, J. 1991. *Corpus, Concordance, Collocation* [M]. Oxford: Oxford University Press.

Sinclair, J. 1996. The search for units of meaning [J]. *Textus* (1): 75-106.

Sinclair, J. 1998. The lexical item [A]. In E. Weigand (ed.). *Contrastive Lexical Semantics* [C]. Amsterdam: John Benjamins. 1-24.

Sinclair, J. 2004. *Trust the Text: Language, Corpus and Discourse* [M]. London and New York: Routledge.

Sinclair, J., S. Jones & R. Daley. 1970. English lexical studies: Report to the Office of Scientific and Technical Information (OSTI) [R]. Birmingham: Department of English, University of Birmingham.

Stefanowitsch, A., K. Middeke & F. Lin. 2023. Nominal constructions in spoken academic Englishes: A quantitative corpus-based approach [J]. *Yearbook of the German Cognitive Linguistics Association* (1): 75-104.

Stubbs, M. 2007a. An example of frequent English phraseology: Distributions, structures and functions [A]. In R. Facchinetti (ed.). *Corpus Linguistics 25 Years on* [C]. Amsterdam: Brill Rodopi. 87-105.

Stubbs, M. 2007b. Quantitative data on multi-word sequences in English: The case of the word world [A]. In M. Hoey, M. Mahlberg, M. Stubbs, *et al*. (eds.). *Text, Discourse and Corpora: Theory and Analysis* [C]. London: Continuum. 163-189.

Stubbs, M. 2009. The search for units of meaning: Sinclair on empirical semantics [J]. *Applied Linguistics* (1): 115-137.

Thompson, P. & A. Sealey. 2007. Through children's eyes?: Corpus evidence of the features of children's literature [J]. *International Journal of Corpus Linguistics* (1): 1-23.

Warren, M. 2009. Why concgram? [A]. In C. Greaves (ed.). *ConcGram 1.0: A Phraseological Search Engine* [C]. Amsterdam: John Benjamins. 1-11.

Wilks, Y. 2005. REVEAL: The notion of anomalous texts in a very large corpus [R]. Tuscany: Tuscan Word Centre International Workshop, Certosa di Pontignano.

何安平.2013.国外语料库语言学视角下多形态短语研究述评[J]. 当代语言学(1): 62-72.

雷蕾、刘迪麟、晏胜.2017.基于窗口与基于句法分析的搭配提取:问题与方法[J].语料库与跨文化研究(1): 13-36.

李文中. 2021. 接着做:扩展意义单位分析[J].当代外语研究(6): 13-26, 88.

刘永芳、陈宗利.2019.中外硕士学位论文英文标题的名词化特征实证性研究[J].外语教学(5):18-23.

卢伟胜、郭躬德、陈黎飞.2014.基于词性标注序列特征提取的微博情感分类[J].计算机应用(10):2869-2873.

王立非、文道荣.2017.商务英语合同的语义范畴与词性分布特征的语料库考察[J].山东外语教学(2):12-20.

吴君、赫里·蒂萨里.2021.中国英语学习者和英语母语者使用程度副词和动词的比较[J]. *Chinese Journal of Applied Linguistics*(4): 470-487.

卫乃兴.2012.共选理论与语料库驱动的短语单位研究[J].解放军外国语学院学报(1): 1-6.

卫乃兴.2009.语料库语言学的方法论及相关理念[J].外语研究(5):36-42.

许家金.2017.体裁短语学视角下的医学学术英语词典研编[J].外语与外语教学(6):52-60.

甄凤超.2020.语料库语言学研究热点追踪与思考[J].当代外语研究(6):89-100.

甄凤超.2023.复合词项语义韵研究再探[J].外语教学与研究(1):41-52.

(责任编辑 邓梦寒)

Towards a Part-of-Speech (PoS) Gram Approach to Corpus-based Phraseology, by LIN Ling & LIU Ming.

Abstract: One of the primary concerns in corpus linguistics is phraseology. This study first gives an extensive review of previous studies on phraseology in

corpus linguistics, and then proposes a new approach to corpus-based phraseology studies, i.e., the Part-of-Speech (PoS) gram procedure. After giving a brief introduction to its definition and key features, this study also addresses the implications of this approach in four different fields of study, including the extraction and analysis of phraseologies, the function of phraseologies, textual studies, and language teaching and learning. It is argued that although this approach has long been ignored in international and domestic linguistic studies, it can provide phraseology studies with new perspectives, new tools, and new findings, which can be a useful supplement to existing approaches and worthy of further exploration and application.

Key Words: phraseology; Part-of-Speech grams; multi-word sequences; corpus linguistics; N-grams

(上接 14 页)

Exploring New Paths in Corpus Stylistics: How does Kazuo Ishiguro Construct the Meaning of Hailsham in *Never Let Me Go*?, by ZHEN Fengchao.

Abstract: By means of quantitatively analyzing language data, corpus stylistics aims to explore the style of literary work. In some degree, however, this kind of study neglects the richness of meaning constructed in the literary work. The textual perspective of meaning analysis in corpus linguistics sheds light on new paths of corpus-based literature study. From the textual perspective, we can observe and analyze relationship of the roles and the line of development hidden in a fiction, and therefore obtain a completely new interpretation of the meaning conveyed in the fiction. Sinclair & Mauranen (2006) proposed the notions of discourse object and discourse incident which can be applied to the interpretation of meaning in literary texts. Hailsham is the center of fictional world constructed in Kazuo Ishiguro's fiction *Never Let Me Go* and the depiction of it runs throughout the whole fiction. The previous studies on Hailsham mainly focus on its humanizing education and the analysis of its failure, neglecting the exquisite subtlety in meaning of Hailsham. This study employs the ideas of discourse object and discourse incident to analyze how Kazuo Ishiguro constructs the semantic network of Hailsham and gives distinctive personality and souls to the characters in spellbinding detail.

Key Words: *Never Let Me Go*; Hailsham; text perspective; corpus linguistics